

Анализатор тональности и частот текстов

Инструкция пользователя

Программа сама выгружает свежие новости из RSS-лент, чистит их, считает частоты слов и настроение, рисует графики и складывает всё в папку. Код писать не нужно.

Курбашкин Никита, Лагунов Матвей, Прохорова Виктория

1. Что делает программа

Программа сама выгружает свежие новости из RSS-лент, обрабатывает их и показывает, о чём они и какое в них настроение. Управление простое: меню и цифры на клавиатуре. Нужен интернет.

Коротко по шагам программа умеет:

- выгрузить новости из RSS-лент (можно из нескольких изданий сразу);
- почистить тексты и привести слова к начальной форме;
- посчитать самые частые слова и нарисовать облако слов;
- оценить настроение новостей (позитив, нейтрал, негатив);
- посчитать статистику и построить графики (это делает R);
- сложить всё в папку output/.

2. Установка (один раз)

Шаг 1. Python-зависимости

Откройте командную строку в папке проекта и наберите:

```
pip install -r requirements.txt
```

Шаг 2. Пакет для R

Поставьте R, затем выполните:

```
Rscript scripts/r/install_packages.R
```

Шаг 3 (по желанию). rpy2

rpy2 это основной способ связи Python и R. Если он не поставится, программа всё равно заработает, просто вызовет R другим способом.


```
pip install rpy2
```

3. Запуск и меню

Запустите программу:

```
python start.py
```

Откроется меню. Чтобы выбрать пункт, наберите его номер и нажмите Enter.

A screenshot of a terminal window with a dark background. The title bar at the top shows three colored circles (red, yellow, green) on the left and the text 'python start.py' on the right. The terminal content displays a menu for 'Анализ тональности и частот текстов Python + R'. It includes a separator line of equals signs, the status 'Данные: не загружены | top-слов: 20', and a numbered list of options: 1. Загрузить данные, 2. Настроить параметры, 3. Запустить анализ, 4. Инструкция (открыть pdf), 5. Открыть папку с результатами, and 0. Выход. The prompt '> _' is at the bottom.

```
python start.py
=====
Анализ тональности и частот текстов
Python + R
=====

Данные: не загружены | top-слов: 20
1. Загрузить данные
2. Настроить параметры
3. Запустить анализ
4. Инструкция (открыть pdf)
5. Открыть папку с результатами
0. Выход
> _
```

Скриншот 1. Главное меню


4. Быстрый сценарий за 4 шага

Шаг 1. Наберите 1 (загрузить данные), потом ещё раз 1, программа скачает новости со всех лент сразу (нужен интернет). Можно вместо этого выбрать одну ленту из списка (2) или ввести свой адрес RSS (3).

Шаг 2. По желанию наберите 2 и поменяйте, сколько топ-слов показывать.

Шаг 3. Наберите 3 (запустить анализ). Программа обработает новости и вызовет R. Несколько секунд.

Шаг 4. Наберите 5, чтобы открыть папку с результатами, или 4, чтобы ещё раз открыть эту инструкцию.



```
результаты анализа

===== РЕЗУЛЬТАТЫ =====
Текстов обработано: 626
Настроение: позитив = 96 , нейтрал = 372 , негатив = 158

Топ слов:
1 россия - 77
2 российский - 67
3 всу - 58
4 сша - 50
5 украина - 49


Облако слов сохранено
Графики и статистика R: ОК

Таблицы лежат в: output/tables
Графики лежат в: output/plots
=====
```

Скриншот 2. Что программа пишет после анализа

5. Как читать результаты


Всё попадает в папку output/: графики в output/plots/, таблицы в output/tables/.




Топ слов: какие слова встречаются чаще всего. Чем длиннее столбец, тем чаще слово.



Распределение тональности: у каждого текста есть оценка от -1 (негатив) до +1 (позитив). Столбцы показывают, сколько текстов в каждом диапазоне.



Тональность по источникам: настроение текстов из разных источников рядом (коробчатая диаграмма).



Динамика по дням: как менялось среднее настроение со временем.



Облако слов: чем крупнее слово, тем чаще оно встречается.

Таблицы (output/tables/)

- documents.csv, тональность каждого текста;
- word_freq.csv, слова и их частоты;
- stats_summary.csv, сводка: сколько текстов, среднее настроение, доли позитивных и негативных;
- stat_tests.txt, результаты тестов Шапиро-Уилка и ANOVA из R.

6. Если что-то пошло не так

Программа не вылетает, а пишет, в чём проблема:

- «Не получилось загрузить ленту»: нет интернета или издание сменило адрес; попробуйте другую ленту из списка (пункт 2).
- «Ошибка ввода»: вы ввели букву вместо цифры; повторите.
- Ошибка R: проверьте, что установлен пакет ggplot2 (шаг 2).
- Если читаете сохранённую выгрузку (csv), в ней нужна колонка text.

Если одна лента не открывается, соберите со всех сразу (пункт 1): остальные всё равно загрузятся.